
title: 机器人学习中的规划与探索方法研究综述

author: 王锦淇

date: 2026年3月11日

- 摘要
- 1. 引言
- 2. FDP：因子化扩散策略
 - 2.1 模块化架构
 - 2.2 多任务学习与适应
 - 2.3 关键优势
- 3. SuS：策略感知的内在探索
 - 3.1 策略稳定性与策略惊喜
 - 3.2 实验验证
- 4. GM-100：细节化机器人任务基准
 - 4.1 任务构建方法
 - 4.2 数据集与评估
- 5. TIDE：基于自动机迹的时序规划
 - 5.1 核心思想
 - 5.2 代价函数设计
 - 5.3 实验表现
- 6. 综合比较
- 7. 未来方向
- 参考文献

摘要

机器人学习领域近年来涌现出众多创新方法，特别是在规划与探索方面。本文综述了四篇代表性工作：FDP（因子化扩散策略）通过模块化扩散模型提升多任务学习性能；SuS（策略感知探索）引入基于策略稳定性和策略惊喜的内在激励机制；GM-100 构建了包含100个细节化任务的机器人学习基准；TIDE 提出了一种基于自动机迹分解的时序扩展目标规划框架。通过对比分析各方法的核心思想、技术路线与实验结果，本文总结了当前机器人规划与探索的优势与不足，并展望了未来发展方向。

1. 引言


机器人学习中的规划与探索是实现通用智能体的关键挑战。传统方法在处理多任务、长时域目标时往往面临扩展性差、探索效率低等问题。近年来，扩散模型、内在动机、大规模基准以及形式化规划方法取得了显著进展。本文选取的四篇论文分别从不同角度切入：FDP 利用因子化扩散模型实现多任务模仿学习；SuS 通过

策略空间中的预测误差驱动探索；GM-100 提供了一套系统的任务基准；TIDE 则基于 LTLf 自动机分解实现时序目标规划。

2. FDP：因子化扩散策略

FDP 的核心思想是将复杂的多任务动作分布分解为多个专门的扩散模块，每个模块捕捉行为空间中的一个子模式，并通过观测条件路由器动态组合。

FDP 因子化扩散策略架构示意图



2.1 模块化架构

如图1所示，FDP 包含多个扩散专家和一个轻量级路由器。每个专家独立建模一个行为模式，路由器根据当前观测输出专家权重，最终动作通过加权聚合生成。这种设计避免了传统 MoE 的训练不稳定和专家重叠问题。

2.2 多任务学习与适应

在 MetaWorld 和 RLBench 上的实验表明，FDP 显著优于 DP、SDP 和 MoDE 基线。例如在 RLBench 上，FDP 的平均成功率达到 63.9%，比 DP 提升 18.3 个百分点。通过添加新模块进行任务适应，仅需更新少量参数即可避免灾难性遗忘。

2.3 关键优势

- 连续分数聚合替代离散专家选择，训练稳定。
- 模块可解释性强，不同专家对应不同行为阶段（如对准、抓取）。
- 支持异构架构，可扩展计算资源匹配任务复杂度。

3. SuS：策略感知的内在探索

SuS 提出了一种基于预-后预测误差的内在奖励机制，鼓励智能体探索导致策略变化的动作，而非单纯的状态新颖性。

3.1 策略稳定性与策略惊喜

SuS 包含两个互补组件：

- **策略稳定性 (SS)**：衡量连续时间步策略嵌入的一致性，鼓励行为连贯。
- **策略惊喜 (SuS)**：结合世界模型预测误差与策略变化，奖励导致意外战略位置的动作。

最终内在奖励为 ($r_{\text{int}} = \lambda_1 \text{SS} + \lambda_2 \text{SuS}$)，权重可自适应学习。

3.2 实验验证

在 GSM8K 数学推理任务上，SuS 使 Qwen2.5-1.5B 的 Pass@1 提升 17.4%，Pass@5 提升 26.4%，并维持更高的策略多样性。消融实验证实两个组件缺一不可。

4. GM-100：细节化机器人任务基准

GM-100 针对现有数据集任务单一、覆盖不全的问题，设计了 100 个涵盖广泛交互与长尾行为的任务，旨在全面评估具身智能体的能力。

4.1 任务构建方法

通过系统分析现有任务设计，结合人类-物体交互基元与物体功能知识，生成 100 个细节化任务。例如：将小球击入桌面球门、用刀切黏土、折叠纸板等。每个任务包含详细的交互步骤和成功标准。

4.2 数据集与评估

在两种机器人平台（Cobot Magic 和 Dobot Xtrainer）上收集了超过 13K 条轨迹。评估了 DP、 π_0 、 $\pi_{0.5}$ 等基线模型，发现 GM-100 任务具有足够挑战性，能有效区分不同 VLA 模型的性能。例如 $\pi_{0.5}$ 在 Xtrainer 上的平均 PSR 达 53.9%，而 DP 仅 7.0%。

5. TIDE：基于自动机迹的时序规划

TIDE 针对 LTLf 时序目标规划问题，提出一种迹引导的深度优先探索框架，避免显式构建完整乘积图。

5.1 核心理念

将 LTLf 公式转化为 DFA，然后选择有希望的 DFA 迹，将其分解为一系列可达-避免子问题，用经典规划器求解。若迹失败，则根据反馈更新代价并回溯。

5.2 代价函数设计


边代价定义为两个状态自环条件所需谓词的变化量，迹排名采用平均代价，引导搜索优先选择易实现的迹。

5.3 实验表现

在 TB15 基准和自定义 Blocksworld 问题上，TIDE 显著优于 FOND4LTLf、Exp、Poly 和 Plan4Past。例如在 Blocksworld 塔反转任务 (n=25) 中，TIDE 仅需 0.548 秒，而 FOND4LTLf 需 4.875 秒，Exp 和 Poly 均超时。

6. 综合比较

下图展示了不同方法在 MetaWorld 上的平均成功率对比（基于 FDP 论文数据）。



方法	核心贡献	关键技术	局限
FDP	多任务扩散策略	因子化扩散模块、路由器聚合	专家数量需手动设定
SuS	内在探索机制	策略稳定性、策略惊喜	双组件权重需自适应
GM-100	细节化任务基准	100 个任务、双平台数据	数据规模相对较小
TIDE	时序目标规划	迹选择、代价驱动回溯	回溯过多时效率下降

7. 未来方向

- **模块化与扩展性：**探索异构专家组合与自动化模块发现。
- **内在动机与稀疏奖励：**将 SuS 类机制扩展到更复杂的环境。
- **任务生成自动化：**利用 LLM 辅助生成更多样化的任务。
- **形式化方法与学习的结合：**将 TIDE 与神经网络规划器融合，提升泛化能力。

参考文献

[1] Liu, C., et al. (2026). Flexible Multitask Learning with Factorized Diffusion Policy. *arXiv:2512.21898*.
[2] Kashirskiy, M., & Makarov, I. (2026). SuS: Strategy-aware Surprise for Intrinsic Exploration. *arXiv:2601.10349*.
[3] Wang, Z., et al. (2026). The Great March 100: 100 Detail-Oriented Tasks for Evaluating Embodied AI Agents. *arXiv:2601.11421*.
[4] Suprun, Y., et al. (2026). TIDE: A Trace-Informed Depth-First Exploration for Planning with Temporally Extended Goals. *arXiv:2601.12141*.